




Universidade Federal de Santa Catarina
Centro Tecnológico de Joinville

Fusão Sensorial e Estimativa de Posicionamento
com
Filtro de Kalman
PPGESE - Estatística para Análise de Dados

Duncan Zancanella, Thiago Ezaú Oleinik

Joinville
2026

Sumário

1	Introdução	2
2	Desenvolvimento	3
2.1	Fundamentação Teórica	3
2.1.1	Teorema de Bayes	3
2.1.2	Filtro de Kalman Linear (KF)	4
2.2	Implementação Genérica do Filtro	7
2.2.1	Código Fonte e Organização	7
2.3	Simulação e Validação	7
2.4	Implementação Prática	8
2.4.1	Hardware	8
2.4.2	Simulador de Física	8

1 Introdução

O objetivo deste trabalho é aplicar os conceitos de inferência bayesiana e processos estocásticos através da implementação de um Filtro de Kalman Linear (KF). Será realizado a fusão sensorial dos dados de uma Unidade de Medida Inercial (IMU) — combinando o Giroscópio e o Acelerômetro — para estimar a atitude (posição/ângulo) de um corpo rígido de forma robusta ao ruído.

2 Desenvolvimento

2.1 Fundamentação Teórica

Antes de explicitar o funcionamento do Filtro de Kalman, é necessário partir dos conceitos base de estatística para demonstrar matematicamente como é possível relacionar duas distribuições de probabilidade normais de a fim de reduzir a incerteza associada à predição e observação. Assim, será possível mostrar como a predição relaciona com a probabilidade a priori e a medição se relaciona com a verossimilhança para gerar a distribuição a posteriori.

2.1.1 Teorema de Bayes

Inicialmente, parte-se da definição da probabilidade da interseção entre dois eventos:

$$P(A \cap B) = P(A|B) \cdot P(B) \quad (1)$$

Caso $P(A) \neq 0$, a probabilidade da interseção pode ser descrita como:

$$P(A \cap B) = P(B|A) \cdot P(A) \quad (2)$$

Desse modo, dado n número de eventos, onde $i \in I = \{1, 2, \dots, n\}$

Partindo da definição de probabilidade condicional mostrada anteriormente,

$$P(A_i|B) = \frac{P(A_i \cap B)}{P(B)} \quad (3)$$

Assim, o total de eventos de B pode ser visto como a união da interseção de todos os eventos mutuamente exclusivos, de modo que a probabilidade resulte em:

$$P(B) = \bigcup_{i=1}^n P(B \cap A_i) = P(B \cap A_1) \cup P(B \cap A_{i+1}) \cup \dots \cup P(B \cap A_n) \quad (4)$$

Lembrando da definição da probabilidade da interseção, a probabilidade de cada evento A_i dada a certeza de B é:

$$P(A_i \cup B) = P(A_i) \cdot P(B|A_i) = P(B \cup A_i) \iff P(B) \neq 0 \quad (5)$$

Logo, substituindo a Equação 5 no numerador e 4 no denominador de 3,

$$P(A_i|B) = \frac{P(A_i) \cdot P(B|A_i)}{\bigcup_{i=1}^n P(B \cap A_i)} \quad (6)$$

Entretanto, pela regra do produto explicitada na (3):

$$\boxed{P(A_i|B) = \frac{P(A_i) \cdot P(B|A_i)}{\sum_{i=1}^n P(A_i) \cdot P(B|A_i)}} \quad \text{Teorema de Bayes} \quad (7)$$

Visto que a união de todos os eventos resulta na soma de cada probabilidade condicional.

Dado dois eventos mutuamente exclusivos, a probabilidade total é resultado da união de cada interseção entre todos os eventos:

$$P(B) = P(B \cap A_i) \cup P(B \cap A_{i+1}) \cup \dots \cup P(B \cap A_n) \quad (8)$$

$$\therefore \boxed{P(B) = \sum_{i=1}^n P(B \cap A_i)} \quad \text{Teorema da Probabilidade Total} \quad (9)$$

2.1.2 Filtro de Kalman Linear (KF)

Para estimar o estado atual $\hat{x}_t$ de um sistema dada uma observação z_t , deseja-se minimizar a diferença entre o estado real e estado previsto como:

$$e = x_t - \hat{x}_t \quad (10)$$

Assim, assumem-se as seguintes hipóteses:

- Erro médio de cada variável é nulo (ruído gaussiano branco);
- Erro de cada variável é independente;
- Modelo de evolução do sistema linearizado;
- Relacionamento linear entre variáveis de estado e observação.

Nesse contexto, parte-se da hipótese de Markov, implicando que o estado atual depende apenas do estado anterior, não havendo necessidade de um histórico acumulado para estimativa e previsão do estado futuro, conforme mostrado na Equação 11.

$$p(x_t|z_t) = \int p(x_t|\hat{x}_t, z_t)p(\hat{x}_{t-1})d\hat{x}_{t-1} \quad (11)$$

Relembrando o Teorema de Bayes, como visto na Equação 12.

$$p(x|z, u) = \frac{p(z|x, u)p(x|u)}{p(z|u)} \quad (12)$$

O processo de filtragem será definido em três etapas: a priori (ou belief), predição e correção. Na primeira etapa, assume-se que a distribuição de probabilidade do sistema é conhecida, representada como:

$$bel(x_t) = p(x_t|z_{1:t}, u_{1:t}) \quad (13)$$

Aplicando o Teorema de Bayes (Equação 12) na Equação 13:

$$p(x_t|z_{1:t}, u_{1:t}) = \frac{p(z_t|x_t, z_{1:t-1}, u_{1:t})p(x_t|z_{1:t-1}, u_{1:t})}{p(z_t|z_{1:t-1}, u_{1:t})} \quad (14)$$

Pela hipótese de Markov e assumindo independência condicional entre observações:

$$p(z_t|z_{1:t-1}, u_{1:t}) = p(z_t|x_t) = 1/\eta \quad (15)$$

Logo, a etapa a priori – isto é, antes de uma observação empírica – é dada como:

$$p(x_t|z_{1:t}, u_{1:t}) = \eta p(z_t|x_t)p(x_t|z_{1:t-1}, u_{1:t}) \quad (16)$$

A etapa de predição (*predict*) permite estimar o próximo estado a partir do modelo de evolução do sistema, denotado como:

$$\overline{bel}(x_t) = p(x_t|z_{1:t-1}, u_{1:t}) \quad (17)$$

$$= \int p(x_t|x_{t-1}, z_{1:t-1}, u_t)p(x_{t-1}|z_{1:t-1}, u_{1:t})dx_{t-1} \quad (18)$$

Já a etapa de correção, ou atualização/*update*, ocorre após a observação z_t do sistema (representando uma medição ou sensor), incorporando a medida no instante t :

$$bel(x_t) = \eta \cdot p(z_t|x_t) \cdot \overline{bel}(x_t) \quad (19)$$

Esse procedimento recursivo é denominado de Filtro Bayesiano, possibilitando estimar o estado a posteriori a partir da observação do sistema, ou seja, a verossimilhança disponível pelo sensor.

Com o intuito de permitir a implementação digital do filtro, define-se o sistema como um processo discreto estocástico, dado na Equação 20.

$$x_t = F_t x_{t-1} + B_t u_t + w_t \quad (20)$$

A matriz F_t representa a transição do sistema entre o estado anterior e posterior, já B_t

representa a matriz de controle determinístico do sistema, com entrada definida pelo vetor u_t .

O observador será definido como:

$$z_t = H_t x_t + v_t \quad (21)$$

Tal que w_t e v_t são ruídos brancos gaussianos da forma:

$$\begin{cases} w_t = \mathcal{N}(0, R_t) \\ v_t = \mathcal{N}(0, Q_t) \end{cases} \quad (22)$$

onde R_t e Q_t são as matrizes de covariância do ruído.

A fim de combinar a distribuição de probabilidade da estimativa da etapa anterior $p(\hat{x}_{t-1})$ e a distribuição de probabilidade da medição $p(z_t)$, realizar-se-á a fusão sensorial para combinar ambas informações e gerar uma nova distribuição de probabilidade de menor variância. Partindo da hipótese de Markov na forma discreta,

$$p(x_t|z_t) = \sum_{\hat{x}_t} p(x_t|\hat{x}_{t-1}, z_t) \cdot p(\hat{x}_{t-1}) \quad (23)$$

Conforme Siegwart (1), aplicando o método de mínimos quadrados na Equação 23, visando reduzir a diferença entre estimativa e estado real, pode-se obter o valor esperado e a variância da nova distribuição de probabilidade. Para o caso de uma dimensão e variável de estado x_t , com estimativa $\hat{x}_t$ e medição z_t , a distribuição de probabilidade é definida como:

$$\begin{cases} \mathcal{N}(\hat{x}_{t-1}, \sigma_1^2) \\ \mathcal{N}(z_t, \sigma_2^2) \end{cases} \quad (24)$$

A combinação entre as distribuições resulta na gaussiana $\mathcal{N}(\hat{x}_t, \sigma^2)$, cujo valor esperado e variância são:

$$\hat{x}_t = \hat{x}_{t-1} + \left(\frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \right) (z_t - \hat{x}_{t-1}) \quad (25)$$

$$\sigma^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2} \quad (26)$$

O ganho de Kalman é definido como:

$$K_t = \left(\frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \right) \quad (27)$$

Generalizando para n variáveis de estado, a forma matricial do filtro de Kalman para o estado a priori, predição e correção tomam a forma:

$$\text{a priori: } \mu_{t-1}, \Sigma_{t-1}, u_t, z_t \quad (28)$$

$$\text{predição: } \overline{bel}(x_t) = \begin{cases} \overline{\mu}_t = F_t x_{t-1} + B_t u_t \\ \overline{\Sigma} = A_t \Sigma_{t-1} A_t^T + R_t \end{cases} \quad (29)$$

$$\text{correção: } bel(x_t) = \begin{cases} \mu_t = \overline{\mu}_t + K_t(z_t - H_t \overline{\mu}_t) \\ \Sigma = (I - K_t H_t) \overline{\Sigma}_t \\ K_t = \overline{\Sigma}_t H_t^T (H_t \overline{\Sigma}_t H_t^T + Q_t)^{-1} \end{cases} \quad (30)$$

Portanto, conhecido o estado anterior do sistema, o filtro de Kalman atua em malha fechada a partir de uma medição para estimar mais acuradamente o estado atual, reduzindo a incerteza e covariância da estimativa.

2.2 Implementação Genérica do Filtro

2.2.1 Código Fonte e Organização

Implementar uma classe genérica em Python para o Filtro de Kalman utilizando exclusivamente a biblioteca numpy para operações matriciais.

- A classe não deve ser fixa para o problema da IMU. Ela deve receber as matrizes estruturais (F, B, H, Q, R, P_0 e x_0) em seu construtor e possuir os métodos independentes `.predict(u)` e `.update(z)`.
- O objetivo desta etapa é avaliar a habilidade de traduzir equações algébricas lineares em código computacional limpo.

2.3 Simulação e Validação

1. Gerar um sinal sintético que represente a inclinação real (ex: uma onda senoidal).
2. Simular o comportamento do Giroscópio (adicionando ruído branco gaussiano de baixa variância à derivada do sinal real).
3. Simular o comportamento do Acelerômetro (adicionando ruído gaussiano de alta variância diretamente sobre o sinal real).

4. Executar o filtro sobre os dados ruidosos, plotar os gráficos comparativos (Real vs. Medido vs. Filtrado) e calcular o Erro Quadrático Médio (EQM) para validar o ganho estatístico.

2.4 Implementação Prática

2.4.1 Hardware

- Utilizar um microcontrolador (Arduino, ESP32, Raspberry Pi Pico, etc.) conectado a uma IMU (ex: MPU6050). O microcontrolador deve coletar as leituras brutas. O filtro de Kalman pode rodar diretamente embarcado (C/C++) ou os dados podem ser enviados via Serial em tempo real para o script Python processar e plotar em formato de Dashboard (ex: usando matplotlib.animation ou dash).

2.4.2 Simulador de Física

- Utilizar um ambiente simulado que forneça telemetria de sensores inerciais passo a passo (ex: CoppeliaSim, Webots, ROS/Gazebo ou mesmo o simulador online Wokwi para programar o microcontrolador virtual). O filtro deve guiar a estimação da pose do robô/objeto simulado.

Referências

- 1 SIEGWART, Roland; NOURBAKHSH, Illah Reza; SCARAMUZZA, Davide.
Introduction to autonomous mobile robots. [*S. l.*]: MIT press, 2011.